Projet 4 : Anticipez les besoins en consommation électrique de bâtiments

Lancelot LECLERCQ

14 décembre 2021

Sommaire

Introduction

Problématique

- Objectif de la ville de Seattle : atteindre la neutralité en émissions de carbone
- La ville s'intéresse aux émissions des batiments non destinés à l'habitation
- Pour cela des relevés de consommation ont été réalisés mais ils sont couteux à obtenir
- Est-il possible de prédire les émissions et de la consommation d'énergie pour des batiments pour lesquels les relevés n'ont pas été réalisé à partir des relevés déjà obtenus

Jeu de données et modélisation

- Base de données issue de l'initiative de la ville de Seattle de proposer ses données en accès libre (Open Data)
- Données concernant les batiments de la ville, caractérise :
  - le type,
  - la surface,
  - le nombre d'étages,
  - la consomation énergétique,
  - les émissions de carbone,
  - :
- Données des années 2015 et 2016

- Objectif : trouver le modèle le plus performant
- Test de modèles de différents type :
  - Linéaires :
    - Ridge
    - Lasso
    - ElasticNet
  - Plus proches voisins :
    - KNeighborsRegressor
  - Ensemblistes :
    - RandomForestRegressor
    - AdaBoostRegressor
    - GradientBoostingRegressor
- GridSearch afin de trouver les paramètres optimaux pour chacuns de ces modèles

Nettoyage du jeu de données

Nettoyage du jeu de données : Correction et selection des données

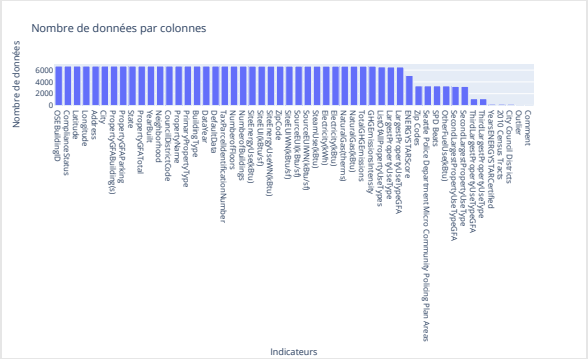

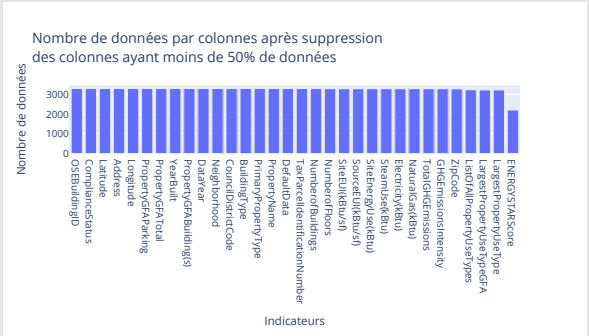

- Nettoyage des valeurs négative pour la surface des batiments/parkings, la consommation et les émissions
- Correction du nombre de d'étages aberrant pour certains batiments
- Lorsque le nombre de batiment est nul on remplace par 1

- Suppression des batiments d'habitation
- Suppression des variables ayant moins de 50% de données
- Suppressions des variables étant des relevés afin de voir si notre modèle peut s'en passer

Nettoyage du jeu de données : Selections des variables

Élimination récursive des variables (RFE) et matrice de corrélation

Variables pertinentes pour les émissions

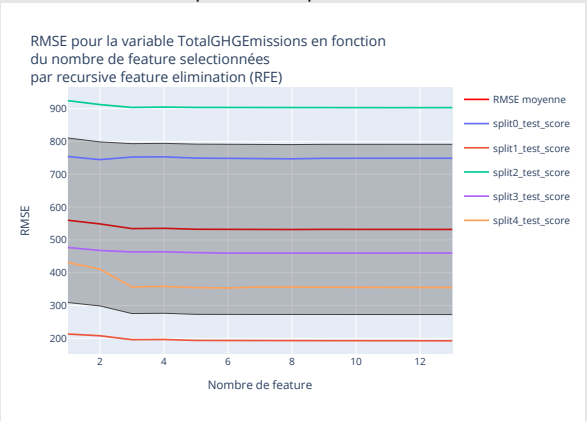

Variables pertinentes pour la consommation

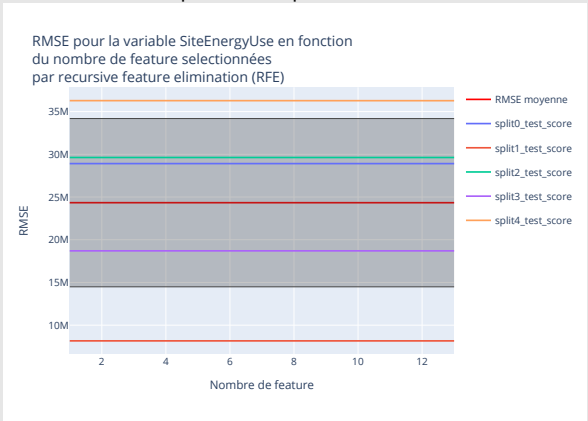

- Selection des variables les plus pertinentes par elimination recursive des variables (RFE)
- Réduction efficace pour les émissions
- Pas de réel changement de RMSE pour la consommation

Nettoyage du jeu de données : Selections des variables

Élimination récursive des variables (RFE) et matrice de corrélation

Variables pertinentes pour les émissions

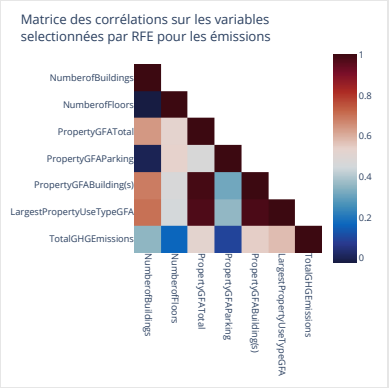

- Observation des résultats de RFE par les matrices de corrélation
- Les variables les plus corrélées sont communes aux deux sélection
- Conservation de 6 variables jugées pertinentes

Variables pertinentes pour la consommation

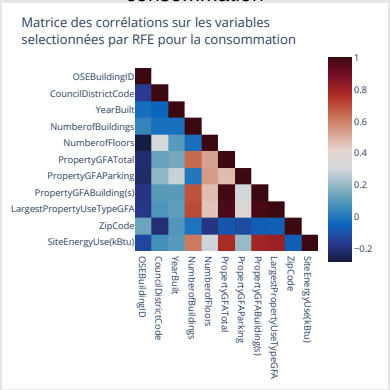

Nettoyage du jeu de données : Selections des variables

Analyse en composantes principales (PCA)

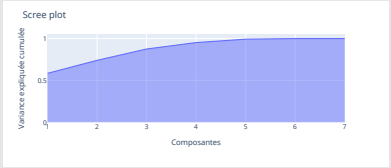

- Le graphique de la variance expliquée cumulée nous montre que 99% de la matrice est exliquée avec 5 variables
- Les quatres variables les plus corrélées se retrouvent sur l'axe F1
- L'EnergyStar score semble avoir une certaine importance car il explique une grande partie de l'axe F3

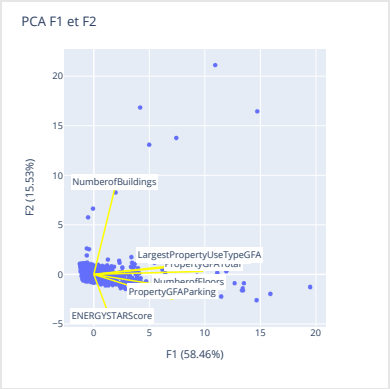

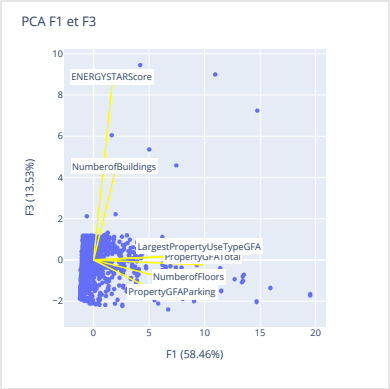

Étapes des modélisations

Étapes des modélisations

Afin de comparer les différents modèles

- Split commun à chaque modèle (varie selon la variable modélisée)
- Pour chaque modèle (boucle) :
  - GridSearch des meilleurs paramètres avec validation croisée
  - Création d'un pipeline : scaling et fit du modèle
    - Scaling par RobustScaler car plus résistant aux valeurs aberrantes selon la documentation
- La boucle retourne :
  - Le(s) meilleur(s) paramètre(s) (gridsearch)
  - La RMSE en fonction du paramètre le plus évolutif (validation croisée)
  - La figure de la variable étudiée vs ses prédictions
  - Le R^2, la RMSE, la MAE (mean absolute error) et le temps de calcul du modèle

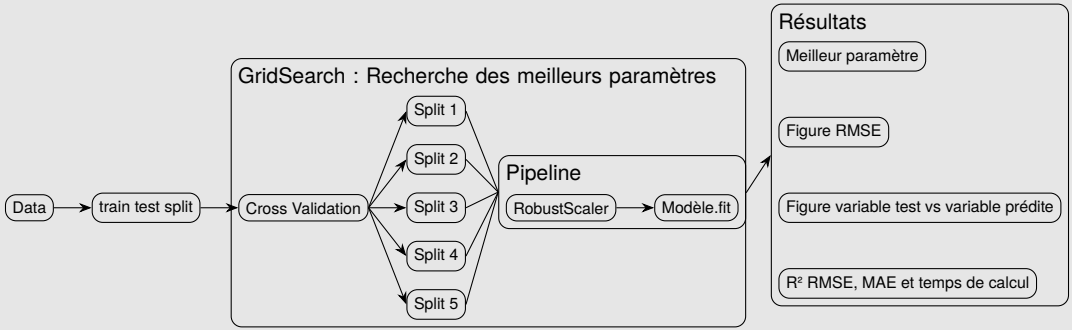

Modélisation émissions

Modèle Ridge

Variable non modifiée

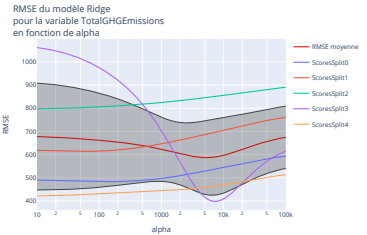

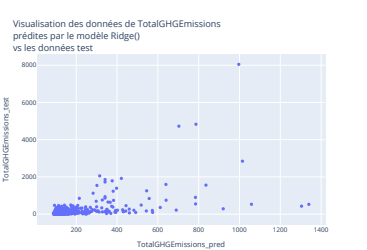

⇐

paramètre	Ridge()
alpha	5094.14

⇐

⇒

paramètre	Ridge()
alpha	6428.07

⇒

- Modèle de régression linéaire introduisant un coefficient cherchant à minimiser l'erreur quadratique

⇐

R^2	RMSE	MAE	MAE%	FitTime(s)
0.24	423.80	150.95	5.72	0.01

⇐

⇒

R^2	RMSE	MAE	MAE%	FitTime(s)
0.16	487.86	135.35	2.12	0.02

⇒

Variable au log

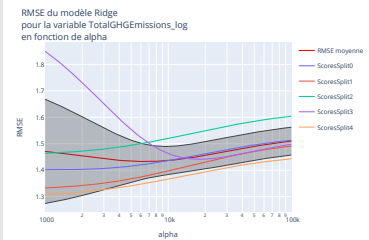

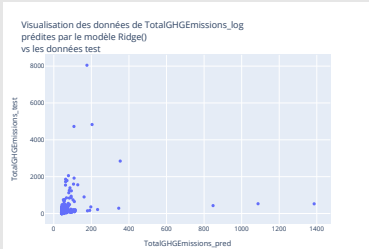

Modèle Lasso

Variable non modifiée

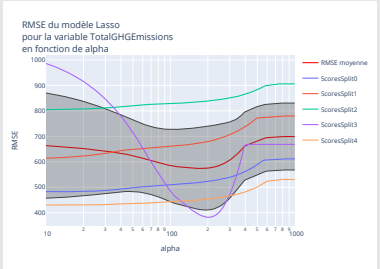

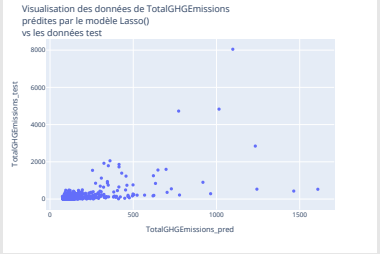

⇐

paramètre	Lasso()
alpha	178.86

⇐

⇒

paramètre	Lasso()
alpha	0.34

⇒

- Similaire à la regression ridge
- Coefficient est réduit à zéro pour les variables peu corrélées
- Peut être utilisé pour la sélection de feature

⇐

R²	RMSE	MAE	MAE%	FitTime(s)
0.26	417.95	150.97	5.52	0.02

⇐

⇒

R²	RMSE	MAE	MAE%	FitTime(s)
0.12	490.73	136.13	2.25	0.02

⇒

Variable au log

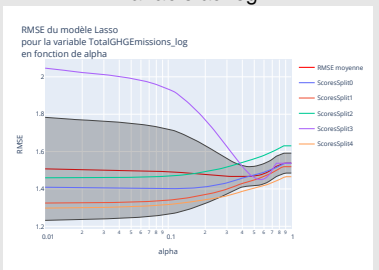

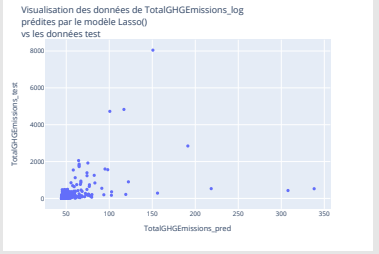

Modèle ElasticNet

Variable non modifiée

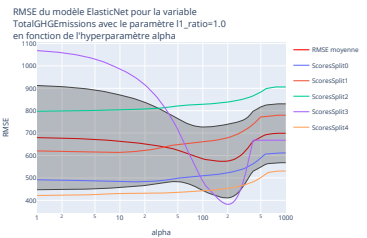

⇐

paramètre	ElasticNet()
alpha	174.75
l1_ratio	1.00

⇐

⇒

paramètre	ElasticNet()
alpha	1.29
l1_ratio	0.10

⇒

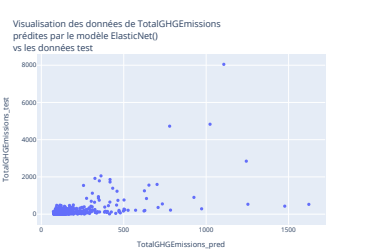

- Combine les coefficients des regressions ridge et lasso

⇐

R²	RMSE	MAE	MAE%	FitTime(s)
0.26	417.53	150.73	5.48	0.01

⇐

⇒

R²	RMSE	MAE	MAE%	FitTime(s)
0.16	487.75	134.58	2.13	0.02

⇒

Variable au log

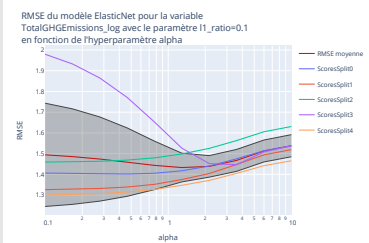

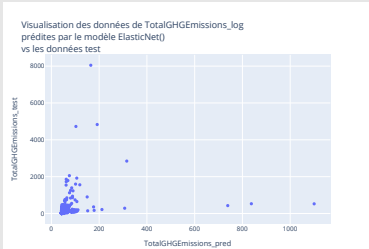

Modèle kNeighborsRegressor

Variable non modifiée

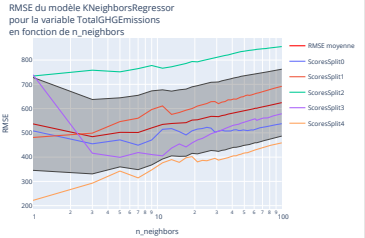

⇐

paramètre	KNeighborsRegressor()
n_neighbors	3

⇐

⇒

paramètre	KNeighborsRegressor()
n_neighbors	1

⇒

- Prédiction par interpolation avec les plus proches voisins dans le jeu de données

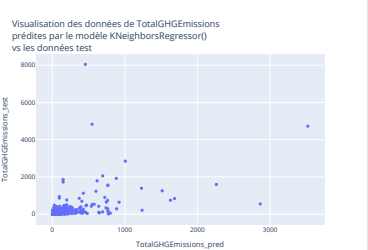

⇐

R^2	RMSE	MAE	MAE%	FitTime(s)
0.26	418.44	119.52	1.99	0.02

⇐

⇒

R^2	RMSE	MAE	MAE%	FitTime(s)
0.52	401.17	73.27	0.75	0.02

⇒

Variable au log

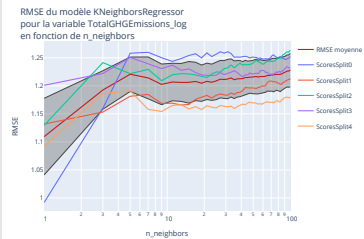

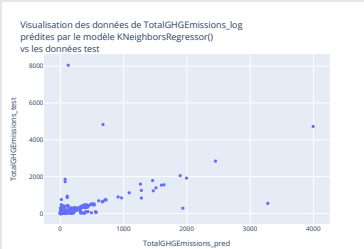

Modèle RandomForestRegressor

Variable non modifiée

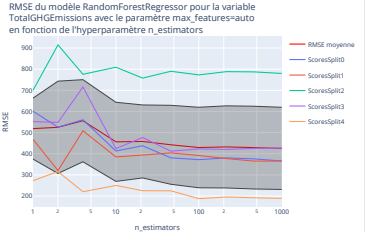

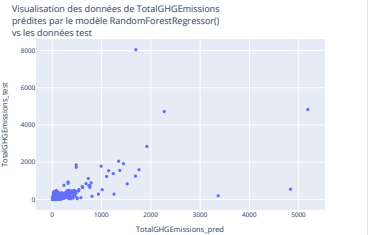

⇐

paramètre	RandomForestRegressor()
n_estimators	1000
max_features	auto

⇐

⇒

paramètre	RandomForestRegressor()
n_estimators	464
max_features	sqrt

⇒

- Classification des valeurs à partir d'arbre de décision aléatoire
- Prédiction à partir de ces classifieurs

⇐

R²	RMSE	MAE	MAE%	FitTime(s)
0.42	371.52	89.73	1.44	11.48

⇐

⇒

R²	RMSE	MAE	MAE%	FitTime(s)
0.68	381.25	85.76	0.72	3.01

⇒

Variable au log

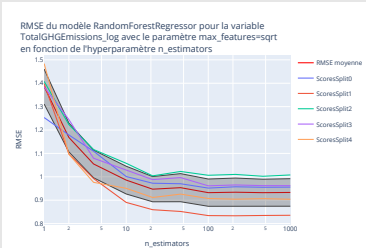

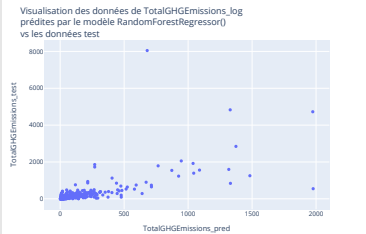

Modèle AdaBoostRegressor

Variable non modifiée

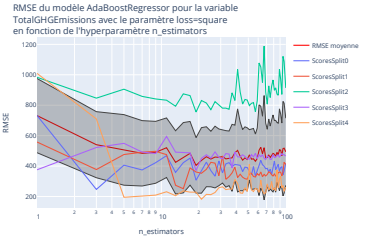

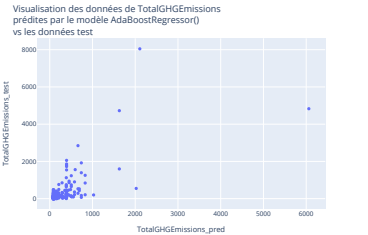

paramètre	AdaBoostRegressor()
n_estimators	19
loss	square

paramètre	AdaBoostRegressor()
n_estimators	15
loss	linear

- Même principe que les forêts aléatoires
- Utilisation d'apprenants faibles (légèrement plus performants que la prediction aléatoire similaire à de petits arbre de décision)
- Les prédictions des apprenants sont combinées avec un coefficient de poids
- À chaque itération le poids des mauvaises prédictions est augmenté ce qui pousse le modèle à se concentrer dessus

R^2	RMSE	MAE	MAE%	FitTime(s)
0.48	351.77	136.67	4.99	0.09

R^2	RMSE	MAE	MAE%	FitTime(s)
0.36	404.36	118.82	1.27	0.09

Variable au log

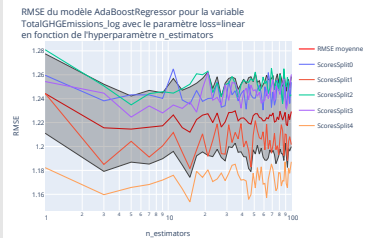

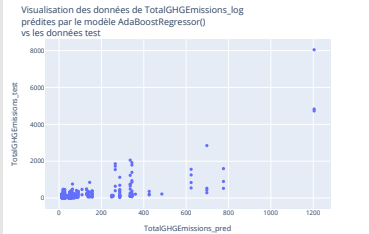

Modèle GradientBoostingRegressor

Variable non modifiée

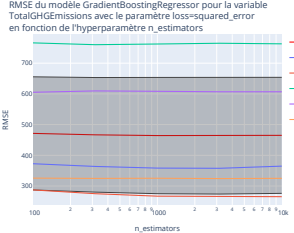

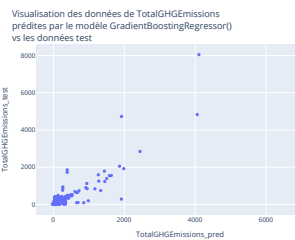

⇐

paramètre	GradientBoostingRegressor()
n_estimators	3162
loss	squared_error

⇐ ⇒

paramètre	GradientBoostingRegressor()
n_estimators	5623
loss	huber

⇒

- Similaire à AdaBoostRegressor
- Prend en compte une fonction objectif (loss fonction) plus complexe afin d'améliorer l'optimisation

⇐

R²	RMSE	MAE	MAE%	FitTime(s)
0.47	355.84	74.99	1.34	10.37

⇐ ⇒

R²	RMSE	MAE	MAE%	FitTime(s)
0.63	340.24	71.60	0.80	55.91

⇒

Variable au log

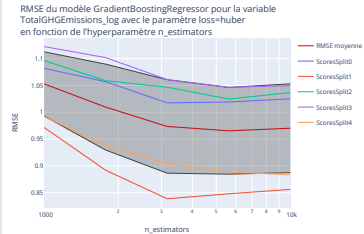

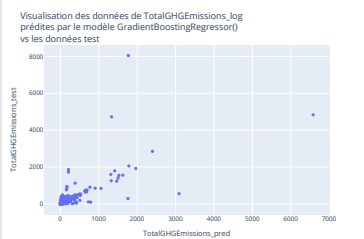

Comparaison des résultats selon que la variable est au log ou non

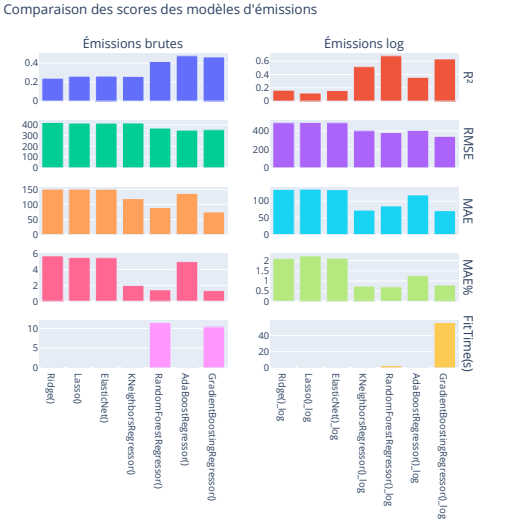

- RandomForestRegressor, AdaBoostRegressor et GradientBoostingRegressor ont des erreur moins importantes et un R^2 plus grand quelque soit la variable modélisée
- KNeighborsRegressor est plus performant avec la variable au log
- Modèles linéaire : Ridge, Lasso et ElasticNet moins efficaces avec la variable au log
- Temps de modélisation de RandomForestRegressor et GradientBoostingRegressor plus importants que les autres
- Temps de modélisation de RandomForestRegressor avec la variable au log moindre qu'avec la variable non modifiée

Influence de l'EnergyStar score sur la prédiction des Émissions

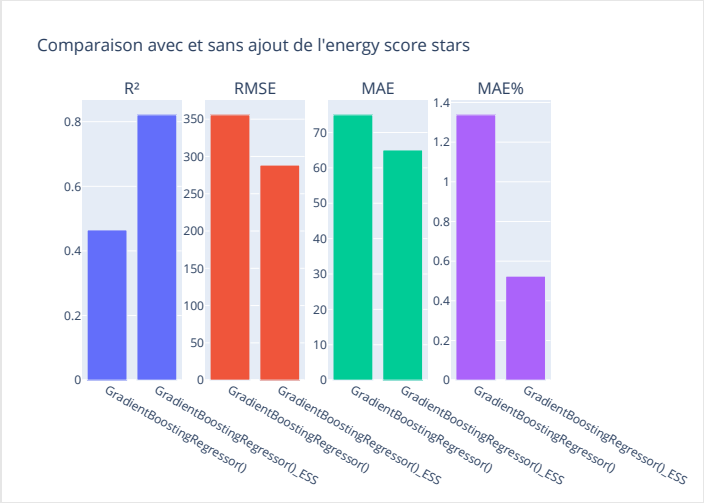

- GradientBoostingRegressor avec la variable au log (RMSE la plus petite)
- L'EnergyStar score améliore la RMSE
- Amélioration des autres mesures d'erreur et de corrélation

Modélisation consommation

Modèle Ridge

Variable non modifiée

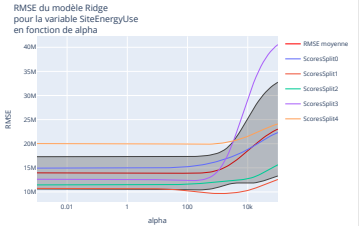

⇐

paramètre	Ridge()
alpha	102.35

⇐

R²	RMSE	MAE	MAE%	FitTime(s)
0.33	17660078.37	5153567.28	1.85	0.01

⇐

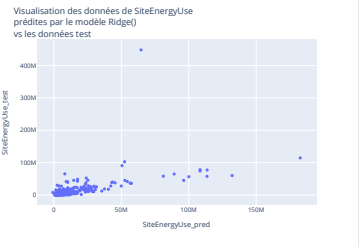

Variable au log

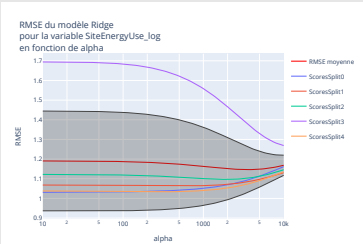

⇒

paramètre	Ridge()
alpha	3511.19

⇒

R²	RMSE	MAE	MAE%	FitTime(s)
0.31	21043685.67	5666820.77	1.40	0.02

⇒

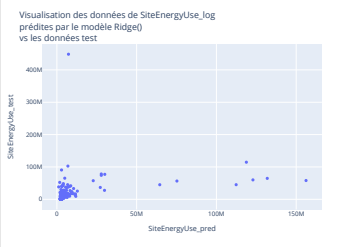

Modèle Lasso

Variable non modifiée

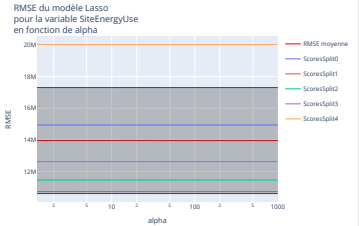

⇐

paramètre	Lasso()
alpha	1000.00

⇐

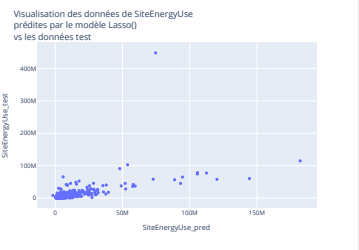

⇐

R²	RMSE	MAE	MAE%	FitTime(s)
0.34	17499302.40	5269886.33	1.88	0.04

⇐

Variable au log

⇒

paramètre	Lasso()
alpha	0.12

⇒

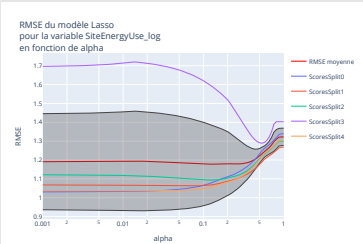

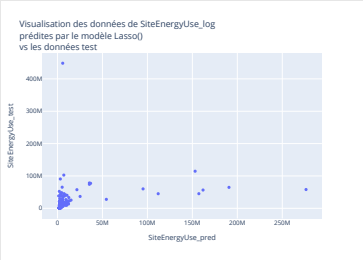

⇒

R²	RMSE	MAE	MAE%	FitTime(s)
0.32	23496263.51	6175023.22	1.38	0.02

⇒

Modèle ElasticNet

Variable non modifiée

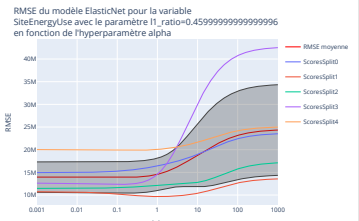

paramètre	ElasticNet()
alpha	0.09
l1_ratio	0.46

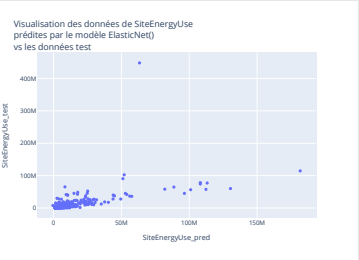

R^2	RMSE	MAE	MAE%	FitTime(s)
0.33	17669838.00	5135486.35	1.85	0.03

R^2	RMSE	MAE	MAE%	FitTime(s)
0.30	20734563.65	5593976.90	1.41	0.02

Variable au log

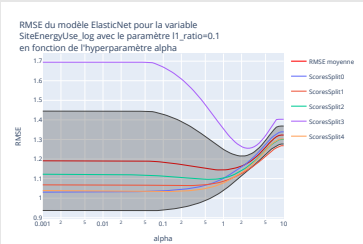

paramètre	ElasticNet()
alpha	0.89
l1_ratio	0.10

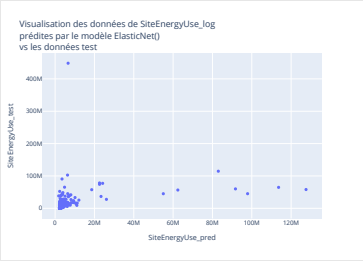

Modèle kNeighborsRegressor

Variable non modifiée

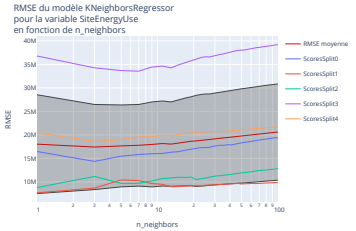

⇐

paramètre	KNeighborsRegressor()
n_neighbors	3

⇐

⇒

paramètre	KNeighborsRegressor()
n_neighbors	1

⇒

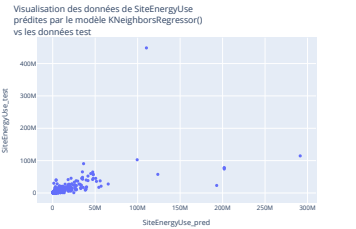

⇐

R²	RMSE	MAE	MAE%	FitTime(s)
0.15	19891776.59	4958197.14	1.14	0.02

⇐

⇒

R²	RMSE	MAE	MAE%	FitTime(s)
0.75	15125790.61	2521110.46	0.55	0.01

⇒

Variable au log

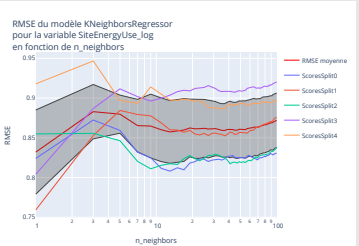

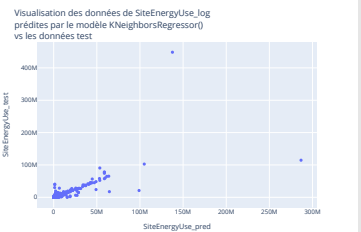

Modèle RandomForestRegressor

Variable non modifiée

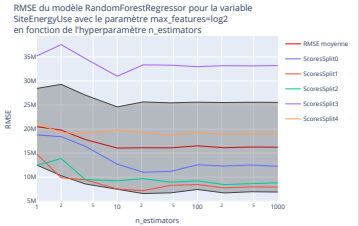

paramètre	RandomForestRegressor()
n_estimators	10
max_features	log2

R²	RMSE	MAE	MAE%	FitTime(s)
0.43	16255496.44	3079266.36	0.85	0.09

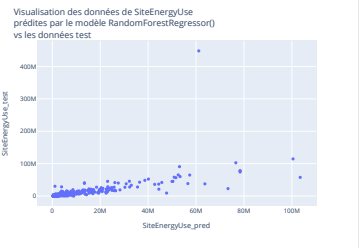

Variable au log

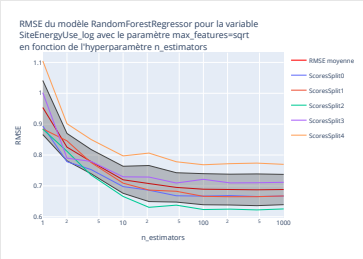

paramètre	RandomForestRegressor()
n_estimators	464
max_features	sqrt

R²	RMSE	MAE	MAE%	FitTime(s)
0.80	16533804.87	2771107.51	0.51	2.72

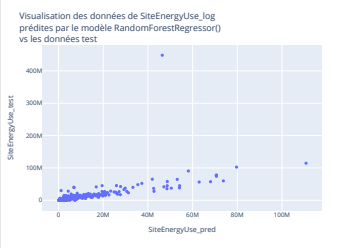

Modèle AdaBoostRegressor

Variable non modifiée

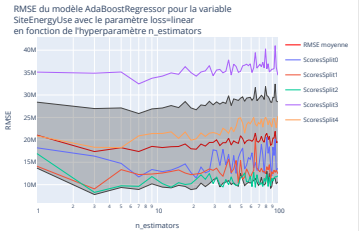

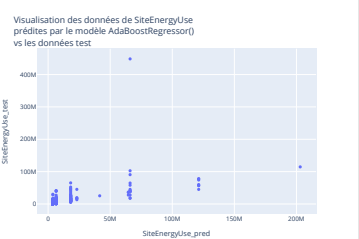

⇐

paramètre	AdaBoostRegressor()
n_estimators	3
loss	linear

⇐

⇒

paramètre	AdaBoostRegressor()
n_estimators	21
loss	exponential

⇒

⇐

R^2	RMSE	MAE	MAE%	FitTime(s)
0.28	18239692.73	5482794.58	2.41	0.05

⇐

⇒

R^2	RMSE	MAE	MAE%	FitTime(s)
0.57	17101356.19	4203072.55	0.83	0.13

⇒

Variable au log

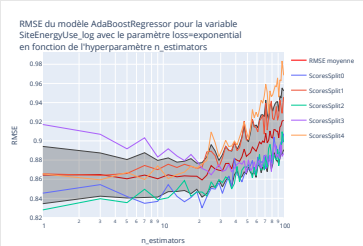

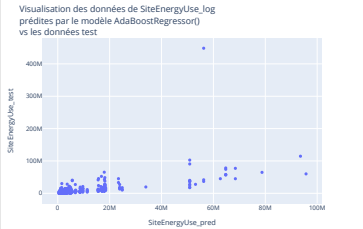

Modèle GradientBoostingRegressor

Variable non modifiée

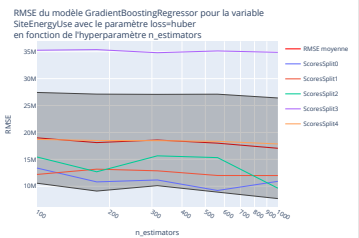

⇐

paramètre	GradientBoostingRegressor()
n_estimators	1000
loss	huber

⇐

⇒

paramètre	GradientBoostingRegressor()
n_estimators	10000
loss	huber

⇒

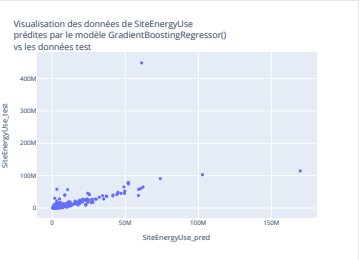

⇐

R^2	RMSE	MAE	MAE%	FitTime(s)
0.43	16292946.43	2980171.79	0.90	7.99

⇐

⇒

R^2	RMSE	MAE	MAE%	FitTime(s)
0.83	15038028.44	2135408.64	0.39	107.33

⇒

Variable au log

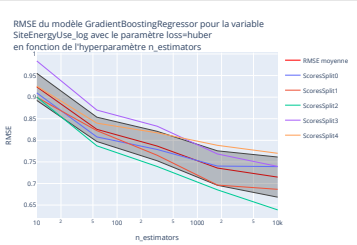

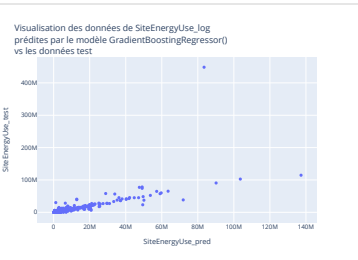

Comparaison des résultats selon que la variable est au log ou non

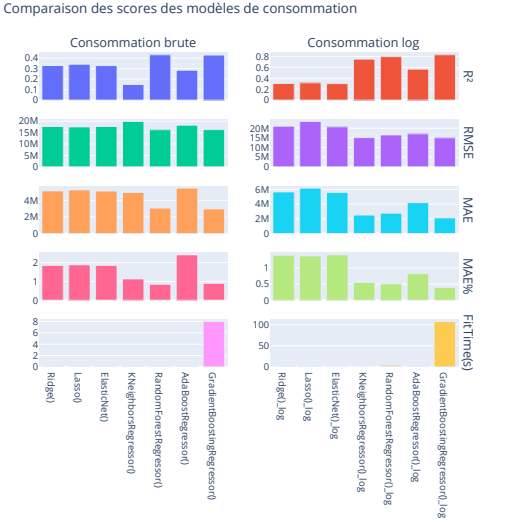

- RMSE KNeighborsRegressor, RandomForestRegressor, AdaBoostRegressor et GradientBoostingRegressor inférieures avec la variable au log

- RMSE de RandomForestRegressor et GradientBoostingRegressor légèrement inférieures quelque soit la variable

- MAE de RandomForestRegressor et GradientBoostingRegressor plus significativement inférieures quelque soit la variable

- Temps de modélisation plus important pour GradientBoostingRegressor

Conclusion

Conclusion : Meilleurs modèles

- GradientBoostingRegressor est le modèle le plus performant dans les deux cas
- Cependant plus gourmant en ressources/temps de calcul
- Peut-être plus difficile à utiliser sur des jeu de données plus importants
- RandomForestRegressor semble être un bon compromis entre performance et temps de calcul
- KNeighborsRegressor semble aussi bien se défendre

Conclusion

- Découverte des différents modèles et de leur fonctionnement
- Obtention avec certains modèles d'une estimation avec moins de 1% d'écart à la moyenne absolue
- Si de nouveaux batiments ont été construits il peut être intéressant de rentrer leurs caractéristiques dans notre base de donnée et voir si on peut prédire leurs émissions et consommation quitte à faire des mesures pour estimer si ces prédictions sont bonnes